



**INSTITUTO POLITÉCNICO
DO CÁVADO E DO AVE
ESCOLA SUPERIOR
DE TECNOLOGIA**

Relatório do Projeto Integrador

APPLIED BUSINESS ANALYTICS, 2025-26

Edgar Couto 34547, Steven Boaventura 34553, Marcelo Dias 36932

1. Introdução

Este projeto consiste na análise aplicada de dados empresariais B2B do dataset ABA26, cobrindo o período 2017–2020 (~120 M\$ de receita, 262 clientes, 43 127 faturas). Foram utilizados Python/Jupyter e Microsoft Power BI para responder a cinco questões analíticas centrais: (i) como segmentar clientes pelo comportamento de compra? (ii) que produtos são comprados em conjunto? (iii) quais os clientes em risco de abandono? (iv) existem transações anómalas? (v) como classificar o portfólio de produtos pela contribuição à receita?

2. Análise Exploratória de Dados (AED)

O dataset é composto por seis ficheiros interligados. A qualidade dos dados é muito elevada — os ficheiros principais estão 100% completos, com exceção de três colunas irrelevantes (backorderid, color, size). A receita apresenta crescimento anual consistente. As distribuições são fortemente assimétricas, com outliers notáveis (ex: máximo de 955 dias de entrega vs. mediana de 1 dia). A carteira de clientes é dominada por Novelty Shops (~68%), concentrados nos territórios Southeast e Mideast. Foi identificado um desalinhamento entre a distribuição de clientes e a alocação de vendedores — territórios com mais clientes têm menos recursos comerciais. --> Notebook ABA26_F06-G4.

Dataset	Linhas	Colunas	Descrição
sales.csv	43 127	12	Registos de vendas/faturas
orders.csv	~43 000	11	Ordens de encomenda
customers.csv	262	8	Dados de clientes B2B
products.csv	~250	10	Catálogo de produtos
employees.csv	~20	9	Equipa comercial
packagetype.csv	~10	3	Tipos de embalagem

3. Segmentação de Clientes — K-Means com RFM

Construíram-se atributos RFM (Recency, Frequency, Monetary) por cliente, enriquecidos com seis atributos complementares (AvgDeliveryDays, TotalProfit, NumProducts, TopCategory, TopTerritory, BuyingGroup). Após normalização (StandardScaler), o número de clusters foi selecionado pelo método Elbow e coeficiente de Silhouette, resultando em $K = 4$. Silhouette Score final > 0.40 , indicando segmentação de qualidade adequada para a dimensão da amostra. --> Notebook ABA26_F01-G4.

Segmento	Perfil	Estratégia Recomendada
0 — Ocasionais	Alta recência, baixa frequência e valor	Campanhas de reativação e up-selling
1 — Premium	Baixa recência, alta frequência e valor elevado	Fidelização e tratamento preferencial
2 — Em Risco	Recência crescente, sinais de afastamento	Contacto proativo, ofertas personalizadas
3 — Regulares	Compras frequentes, valor médio	Manutenção e programas de lealdade

4. Market Basket Analysis — Regras de Associação

Aplicaram-se os algoritmos Apriori e FP-Growth para identificar padrões de co-compra. A unidade de transação foi o cliente (em vez da fatura), dado que 262 clientes em 43 127 faturas geraria uma matriz binária com densidade ~ 0.014 — demasiado esparsa para identificar itemsets frequentes. Parâmetros: min_support = 0.05, min_confidence = 0.30, min_lift = 1.38. As regras identificadas revelam oportunidades concretas de cross-selling — produtos com lift > 1.38 devem ser promovidos conjuntamente (bundles, sugestões automáticas, recomendações comerciais). Uma análise de extensão por território permitiu identificar padrões geograficamente diferenciados. --> Notebook: ABA26_F02-G4

5. Previsão de Abandono (Churn) — Classificação Supervisionada

Definição de churn: cliente sem qualquer compra nos últimos 6 meses do período. O dataset apresenta forte desequilíbrio ($\sim 8\%$ churn), pelo que a métrica principal de avaliação foi AUC-ROC. O pipeline incluiu codificação one-hot, split estratificado 75/25 e normalização StandardScaler.

A Recência é o preditor mais importante de churn (Random Forest feature importance). Recomenda-se o Random Forest em produção pelo equilíbrio performance/robustez, com ajuste de threshold em função do custo relativo entre falsos positivos e falsos negativos. --> Notebook: ABA26_F03-G4.

Modelo	AUC Teste	AUC Cross-Val (5k)	Notas
Logistic Regression	1.000	0.994	Melhor discriminação; padrões RFM lineares
Random Forest	0.937	0.941	Mais robusto; recomendado para produção
Decision Tree	0.900	~0.88	Interpretável; menor estabilidade

6. Detecção de Anomalias — SMOTE, Isolation Forest e LOF

Anomalia definida como: $\text{deliverydays} \geq 7$ (P99) OU $\text{lineprofit} < 0$, resultando em ~3% de anomalias. O desequilíbrio foi tratado com SMOTE no conjunto de treino. O Random Forest com SMOTE obteve desempenho muito elevado (AP próximo de 1.0). Os modelos não-supervisionados (Isolation Forest, LOF) foram inferiores, pois as anomalias são definidas por regras de negócio e não constituem pontos isolados no espaço de features — exigindo supervisão. Recomenda-se monitorização periódica com alertas automáticos para transações com score de anomalia elevado. --> Notebook: ABA26_F04-G4.

7. Análise ABC, Pareto e KPIs Operacionais

A classificação ABC confirma o princípio de Pareto: um número reduzido de produtos (classe A, $\leq 80\%$ receita cumulativa) é responsável pela maioria da faturação. Os produtos classe C, apesar de numerosos, têm impacto marginal e devem ser avaliados quanto à sua manutenção no catálogo. KPIs mensais (Receita, Lucro, Margem %, Faturas, Clientes ativos) foram calculados para suportar análise temporal e identificação de sazonalidade. --> Notebook: ABA26_F05-G4.

Classe	Critério	Ação Estratégica
A	Primeiros 80% da receita	Prioridade máxima — stock, negociação, foco comercial
B	80% a 95% da receita	Gestão corrente — monitorizar evolução
C	Últimos 5% da receita	Avaliar descontinuação ou racionalização

8. Modelação e Dashboards em Power BI

Modelo de Dados

Esquema em constelação com a tabela de factos sales e orders, e dimensões customers, products, employees e package type. Transformações no Power Query: conversão de tipos, criação de colunas auxiliares (YearMonth, profit_margin), filtragem de inconsistências. Tabela de calendário (DimDate) criada para análise temporal correta. Segmentos K-Means importados do Notebook F01.

Principais Medidas DAX

- Total Revenue = SUM(sales[total_amount])
- Total Profit = SUM(sales[lineprofit])
- Profit Margin % = DIVIDE([Total Profit], [Total Revenue], 0)
- Avg Delivery Days = AVERAGE(sales[deliverydays])
- Customer Count = DISTINCTCOUNT(sales[customerid])
- Revenue YoY % = Variação anual vs. período homólogo
- ABC Class = Coluna calculada de classificação por produto

Páginas de Dashboard

Visão Geral

Página de entrada com quatro KPIs de topo: Receita Total (120,83 M\$), Lucro Total (52,35 M\$), Total Clientes (262) e Total Anomalias (1.282). Para cada indicador é apresentado o crescimento Year-over-Year (YoY): +63,53% em receita, +38,71% em lucro e +26,57% em clientes. Os gráficos de barras mostram a Receita Trimestral (de 4,1 M\$ no Q1 2017 até 11,4 M\$ no pico de 2019) e o Crescimento de Clientes trimestral (de 90 para 232). Na parte inferior, três gráficos de rosca sintetizam os Segmentos RFM (93,13% Clientes Ocasionais, 6,11% Inativos), o Risco de Abandono (91,91% Baixo, 7,66% Alto) e a proporção de Anómalas vs Normais (3,67% de anomalias). Inclui filtro de período e filtro por Região.

Análise RFM

Dashboard de segmentação de clientes com quatro KPIs: 2 Clientes Premium, 244 Clientes Ocasionais, 16 Clientes Inativos e 71,06 M\$ de Receita Premium (crescimento YoY de 461,18 K). A tabela Métricas por Segmento detalha, para cada grupo, o número de clientes, Recency médio, Frequency médio e Receita média — os Clientes Premium têm Recency médio de 1 dia, Frequency de 12.674 e Receita média de 35,5 M\$; os Inativos têm Recency de 638 dias. O Mapa RFM (scatter Recency vs Frequency em log) posiciona cada cliente individualmente. O gráfico de barras Receita por Segmento evidencia a enorme assimetria entre Premium (~70 M\$) e inativos (~0). O gráfico horizontal Top Categorias por Segmento mostra que Novelty Shop e Supermarket dominam em número de clientes por todas as categorias.

Deteção de Anomalias

Página dedicada à monitorização de transações suspeitas, com quatro KPIs: 1.282 Total Anomalias, 34 K Transações Normais, 1,21 K Valor Médio Anómalo e 3,7% de taxa de anomalias. Uma caixa de

texto explica a definição de anomalia: entrega ≥ 7 dias ou lineprofit negativo. O histograma de Distribuição de Probabilidade de Anomalia mostra que a esmagadora maioria das transações tem probabilidade baixa (0–10%), com uma cauda de alto risco. O gráfico Valor: Anômalo vs Normal compara valor médio e mediana entre os dois grupos, evidenciando que as transações anômalas têm valor médio e mediana superiores às normais. O gráfico Top 10 Produtos com Anomalias identifica as variantes de Halloween zombie masks como os produtos com maior número de anomalias (até 183). O gráfico Anomalias por Tipo de Embalagem mostra que 'Each' concentra praticamente todas as anomalias.

Análise MBA

Dashboard de Market Basket Analysis com quatro KPIs: 45 K Total Ordens, 40 K Ordens Multi-Produto, 227 Produtos Distintos e 66 Pares Analisados. O gráfico de rosca Top Categorias de Cliente mostra distribuição equilibrada entre Novelty Shop (22,52%), Supermarket (22,14%), Computer Store (19,47%), Gift Store (18,32%) e Corporate (17,56%). A tabela Top Associações de Produtos lista as 10 regras mais relevantes com Produto A, Produto B, Suporte, Confiança e Lift — os melhores pares atingem confiança de 87,50% e lift de 1,42 (ex: 'Ride on vintage American toy coupe → IT joke mug hardware'). O gráfico horizontal Top 10 Pares por Força de Associação visualiza o lift de cada par. O scatter Support vs Confidence (com tamanho proporcional ao Lift) permite identificar as regras com melhor equilíbrio entre frequência e força de associação.

Previsão Abandono

Dashboard de churn com quatro KPIs: 18 Clientes Alto Risco, 1 Cliente Médio Risco, 216 Clientes Baixo Risco e 14,7% de Probabilidade Média de Churn. O histograma de Distribuição de Probabilidade de Churn mostra que a maioria dos clientes tem probabilidade muito baixa (0–10%), com uma pequena concentração em 90–100%. O gráfico Churn Médio por Segmento RFM confirma que os Clientes Inativos têm probabilidade média de churn próxima de 1,0 (100%), os Ocasionais são muito baixos e os Premium são praticamente nulos. A tabela Clientes em Risco de Abandono lista os 18 clientes de alto risco com Customer ID, Segmento, Probabilidade de Churn (100% para a maioria), Receita e Recency — permitindo priorização imediata. O gráfico Risco por Segmento reforça visualmente que o risco está concentrado nos Clientes Inativos.

Análises de Clientes

Página de análise geográfica e de performance de clientes. O gráfico Top 15 Clientes por Revenue destaca Wingtip Toys (Head Office) e Tailspin Toys (Head Office) muito acima dos restantes (ambos acima de 30 M\$), com os demais clientes a gerar menos de 5 M\$ cada. O gráfico Revenue por Território confirma Rocky Mountain e Plains como líderes em receita (acima de 40 M\$ e 38 M\$ respectivamente), seguidos de Southeast e Mid-Atlantic US. O mapa de Distribuição de Vendedores

por Território (modo Night) representa com bolhas a cobertura territorial da equipa comercial — revelando gaps como o Rocky Mountain sem vendedor dedicado apesar de liderar em receita. O mapa de Distribuição de Clientes por Território (modo Grayscale) mostra a localização geográfica de todos os clientes pelos EUA, com maior densidade no centro e este do país.

9. Conclusão

O projeto demonstrou a aplicação integrada de técnicas de analytics de negócio a um dataset B2B real. Os principais contributos incluem: uma segmentação acionável de clientes (K-Means, 4 segmentos), regras de cross-selling quantificadas (MBA, lift > 1.38), modelos preditivos de churn com AUC > 0.90, deteção supervisionada de anomalias operacionais e classificação ABC do portfólio. A combinação Python + Power BI revelou-se eficaz: Python para modelação avançada, Power BI para comunicação executiva dos resultados. Como limitação principal destaca-se a dimensão reduzida da amostra de clientes (262), que pode condicionar a generalização dos modelos preditivos.